

Estudo e análise de mercado financeiro utilizando ferramentas de Deep Learning e Redes Neurais Convolucionais (CNNs)

Adriano Matoba Lipski, Gabrielly de Queiroz Pereira¹

¹Bacharelado Engenharia de Software
Universidade Estadual de Ponta Grossa
Paraná – PR – Brasil

23008123@uepg.br

Abstract. *The growing accessibility of stock market and derivatives has exposed investors to highly volatile financial scenarios, often accompanied by a lack of analytical tools for market analysis and risk management. With that in mind, the current article proposes the development and evaluation of a hybrid Artificial Intelligence architecture, integrating Convolutional Neural Networks (CNNs) with Long Short-Term Memory (LSTM), for trend predictions and loss mitigations in the Brazilian future market. The methodology constitutes of the collection of intraday time series of continuous contracts from Mini Ibovespa Index Futures (WIN) and Mini US Dollar Futures (WDO). The data will be sanitized beforehand, with Min-Max scaler normalization and temporal alignment, in order to stabilize the network gradients. The AI model performance will be evaluated regarding different perspectives, with statistical metrics, classification and business metrics through Backtesting simulations (Sharpe Ratio and Maximum Drawdown), complemented by a risk management analysis based on a simplified Value at Risk (VaR). It is expected that the hybrid model will be capable of extracting morphological patterns and long-term temporal trend patterns, consolidating it as an efficient support tool for financial decision making.*

Key-words: Artificial Intelligence, CNN-LSTM, Future market, Risk management, Temporal Series.

Resumo. *A crescente democratização do acesso ao mercado de derivativos tem exposto investidores a cenários de alta volatilidade financeira, muitas vezes desprovidos de ferramentas analíticas para a análise de mercado e o gerenciamento de risco. Diante disso, este trabalho propõe o desenvolvimento e a avaliação de uma arquitetura híbrida de Inteligência Artificial, integrando Redes Neurais Convolucionais (CNNs) e Long Short-Term Memory (LSTM), para a previsão de tendências e mitigação de perdas no mercado futuro brasileiro. A metodologia compreende a coleta de séries temporais intradiárias dos contratos contínuos do Mini Índice (WIN) e Mini Dólar (WDO). Os dados passarão por processos de sanitização, incluindo normalização Min-Max Scaler e alinhamento temporal, visando a estabilidade dos gradientes da rede. O desempenho dos modelos especializados será avaliado de forma multidimensional por meio de métricas estatísticas, de classificação e de negócio através de simulações de Backtesting (Sharpe Ratio e Maximum Drawdown), complementadas por uma análise de gestão de risco fundamentada no Valor em Risco (VaR) simplificado. Espera-se que o modelo híbrido demonstre capacidade adaptativa*

para extrair padrões morfológicos e dependências temporais de longo prazo, consolidando-se como uma ferramenta eficiente de suporte à tomada de decisão financeira.

Palavras-chave: Inteligência Artificial. CNN-LSTM. Mercado Futuro. Gestão de Risco. Séries Temporais.

1. Introdução

O mercado financeiro contemporâneo caracteriza-se por sua elevada complexidade, presença de ruído, natureza não-linear e mudanças constantes de comportamento, o que impõe desafios severos aos métodos estatísticos e econométricos tradicionais [Al-Alawi and Alaali 2023]. A volatilidade intrínseca dos ativos e a incapacidade de abordagens lineares clássicas em capturar as interdependências de séries temporais de alta frequência impulsionam a transição para sistemas orientados a dados (*data-driven*), fundamentados em Inteligência Artificial [Meena and Banyal 2024]. Nesse cenário, a busca por mecanismos de previsão de movimentos consolida-se como a base para o desenvolvimento de ferramentas avançadas de apoio à tomada de decisão e mitigação de perdas financeiras [Khan et al. 2025].

Nos últimos anos, as técnicas de Machine Learning e, mais especificamente, de Deep Learning emergiram como o estado da arte para a análise de dados financeiros, apresentando resultados consistentemente superiores em relação a modelos tradicionais em diversos cenários [Saini et al. 2024]. Graças à sua capacidade de aproximar funções matemáticas complexas e extrair representações abstratas a partir de grandes volumes de dados históricos, essas arquiteturas conseguem identificar padrões ocultos que métodos convencionais não conseguem representar adequadamente [Khan et al. 2025, Khurelbaatar and Togtokh 2025].

Dentre as diversas famílias de redes neurais profundas, destacam-se na literatura as redes de memória de longo prazo (*Long Short-Term Memory* – LSTM), projetadas especificamente para tratar dados sequenciais e capturar dependências temporais de longo prazo presentes nas séries financeiras [Patil et al. 2024]. Paralelamente, as Redes Neurais Convolucionais (CNNs), embora originadas no campo da visão computacional, ganharam relevância por tratar séries temporais como estruturas unidimensionais, realizando a extração de características relevantes e assinaturas locais para a previsão de preços [Saini et al. 2024, Zhu 2024]. A tendência mais recente da literatura aponta para o uso de modelos híbridos que combinam CNN e LSTM, permitindo que a primeira realize a extração de padrões espaciais/morfológicos locais enquanto a segunda captura a dinâmica temporal de longo prazo [Meena and Banyal 2024, Li 2024].

Contudo, a aplicação prática dessas ferramentas esbarra em desafios metodológicos de calibração estrutural e eficiência dimensional, exigindo um pipeline que processe adequadamente o fluxo de dados sem demandar infraestruturas computacionais de alto custo. Diante desse panorama, surge o seguinte problema de pesquisa: "De que forma a aplicação e a modelagem estruturada de técnicas de Deep Learning podem otimizar a extração de padrões e a análise de risco em séries temporais complexas do mercado financeiro?"

1.1. Objetivos

1.1.1. Objetivo Geral

Realizar um estudo e análise do mercado financeiro utilizando técnicas de Deep Learning e CNN.

1.1.2. Objetivos Específicos

- Realizar uma revisão bibliográfica sobre a aplicação de Deep Learning no mercado financeiro.
- Estudar o funcionamento das Redes Neurais Convolucionais e sua aplicação em séries temporais financeiras.
- Coletar e preparar dados históricos do mercado financeiro para utilização nos modelos.
- Aplicar técnicas de pré-processamento e normalização dos dados financeiros.
- Desenvolver e treinar um modelo baseado em Redes Neurais Convolucionais para análise de dados do mercado financeiro.
- Avaliar o desempenho do modelo utilizando métricas de erro e análise de resultados.
- Analisar os resultados obtidos e discutir a aplicabilidade do Deep Learning na análise do mercado financeiro.

2. Referencial Teórico

O mercado financeiro é caracterizado por alta complexidade, presença de ruído, não-linearidade e mudanças constantes de comportamento, o que dificulta a modelagem por métodos estatísticos tradicionais [Al-Alawi and Alaali 2023]. Nesse contexto, técnicas de aprendizado de máquina e aprendizado profundo passaram a ser utilizadas para análise e previsão de séries temporais financeiras, pois possuem capacidade de modelar relações complexas presentes nos dados de mercado [Meena and Banyal 2024].

Os modelos de Deep Learning têm sido aplicados na previsão de preços de ações, índices financeiros e análise de risco, apresentando resultados superiores em relação a modelos lineares tradicionais em diversos cenários [Saini et al. 2024]. Esses modelos são capazes de identificar padrões ocultos em grandes volumes de dados históricos, permitindo a construção de sistemas de apoio à decisão no mercado financeiro [Khan et al. 2025].

Entre as arquiteturas mais utilizadas estão as Redes Neurais Recorrentes (RNN) e as redes Long Short-Term Memory (LSTM), que são projetadas para trabalhar com dados sequenciais e séries temporais [Aliyev et al. 2022]. As redes LSTM possuem mecanismos de memória que permitem armazenar informações relevantes ao longo do tempo, sendo capazes de capturar dependências temporais de longo prazo presentes nos dados financeiros [Patil et al. 2024]. Além disso, arquiteturas mais profundas, como Stacked LSTM, permitem a extração de características mais abstratas dos dados, reduzindo o erro de previsão quando comparadas a modelos mais simples [Jaswanth and Kaushik 2022].

As Redes Neurais Convolucionais (CNNs), embora originalmente desenvolvidas para processamento de imagens, também têm sido aplicadas em séries temporais finan-

ceiras devido à sua capacidade de extrair padrões locais e identificar tendências de curto prazo [Saini et al. 2024]. Essas redes podem tratar séries temporais como estruturas unidimensionais, realizando a extração de características relevantes para a previsão de preços [Zhu 2024]. Além disso, CNNs também têm sido utilizadas para análise de sentimentos do mercado, melhorando a previsão de movimentos de preços em períodos de maior volatilidade [Yang 2025].

A literatura recente também destaca o uso de modelos híbridos que combinam diferentes arquiteturas de Deep Learning, buscando aproveitar as vantagens de cada modelo [Meena and Banyal 2024]. Modelos que combinam CNN e LSTM permitem que a CNN realize a extração de padrões locais enquanto a LSTM captura dependências temporais de longo prazo [Li 2024]. Essa combinação tem apresentado melhores resultados em comparação com modelos isolados, pois permite representar tanto padrões espaciais quanto temporais presentes nos dados financeiros [Baswaraj et al. 2023]. Além disso, mecanismos de atenção podem ser incorporados a esses modelos para priorizar informações mais relevantes ao longo do tempo [Li 2024].

Outra abordagem relevante é o uso de Aprendizado por Reforço Profundo (Deep Reinforcement Learning), que permite a criação de agentes capazes de tomar decisões de compra e venda com base na maximização de recompensas financeiras [Luthfianti et al. 2022]. Algoritmos como Deep Q-Network (DQN) permitem que o modelo aprenda estratégias de negociação a partir da interação com o ambiente de mercado, ajustando suas decisões de acordo com a volatilidade e as condições do mercado [Khan et al. 2023]. Esse tipo de abordagem é utilizado principalmente em problemas de alocação de portfólio e trading algorítmico [Khan et al. 2025].

Além da previsão de preços, o Deep Learning também pode ser utilizado na análise de risco financeiro. Modelos híbridos que combinam técnicas econométricas, como GARCH, com redes neurais profundas têm sido utilizados para melhorar a previsão de risco baseada em métricas como Value at Risk (VaR) [Jin 2025a]. Essa abordagem permite capturar padrões de volatilidade que modelos estatísticos tradicionais não conseguem representar adequadamente.

Outro aspecto importante na modelagem de dados financeiros é a engenharia de atributos. O uso de indicadores técnicos, como RSI, médias móveis e MACD, pode melhorar o desempenho de modelos de Deep Learning, pois esses indicadores ajudam a representar tendências e padrões do mercado [Mohammed 2022]. Além disso, etapas de pré-processamento como normalização e redução de ruído são fundamentais para melhorar o desempenho dos modelos, especialmente em mercados com baixa liquidez ou alta volatilidade [Khurelbaatar and Togtokh 2025].

Estudos recentes também exploram modelos baseados em grafos, como Graph Convolutional Networks (GCN), que permitem modelar a interdependência entre diferentes mercados financeiros e ativos [Jin 2025b]. Esses modelos consideram que os mercados não são independentes, mas sim conectados por relações econômicas e financeiras, o que pode melhorar a previsão de índices e ativos financeiros.

De forma geral, observa-se que o uso de Deep Learning no mercado financeiro envolve diferentes abordagens, incluindo modelos preditivos, modelos de decisão, modelos híbridos e modelos de análise de risco [Meena and Banyal 2024]. As Redes Neurais

Convolucionais se destacam na extração de padrões locais, enquanto redes recorrentes capturam dependências temporais, e modelos híbridos combinam essas características para melhorar o desempenho das previsões [Al-Alawi and Alaali 2023]. Dessa forma, o uso dessas técnicas permite o desenvolvimento de sistemas capazes de analisar o mercado financeiro de forma automatizada, identificando padrões, tendências e riscos a partir de grandes volumes de dados históricos.

3. Metodologia

3.1. Revisão bibliográfica

A revisão de literatura foi realizada inicialmente com um fichamento de artigos científicos publicados em revistas e conferências. A seleção dos artigos foi realizada nas plataformas IEEE Xplore e ACM Digital Library, utilizando as palavras chaves “deep learning”, “stock market”, “financial market” e variações desses termos juntamente com operadores booleanos. Como critério de inclusão, estabeleceu-se filtros por data, buscando publicações realizadas apenas após 2021 para assegurar uma base bibliográfica atualizada.

O processo de seleção priorizou estudos que apresentassem implementações práticas de modelos preditivos e métricas de desempenho confiáveis para servir de base teórica para a estruturação dos modelos propostos neste trabalho.

3.2. Coleta e sanitização de dados

Para o presente trabalho, os dados serão coletados a partir da Meta Trader 5, uma das plataformas de operações no mercado financeiro mais utilizadas nos dias atuais, que é alimentada com dados precisos fragmentados em múltiplos intervalos de tempo. A coleta das séries temporais será focada no Índice Ibovespa Futuro Mini (WIN\$) e o Contrato Futuro de Dólar Comercial Mini (WDO\$) para fins de modelagem via Redes Neurais Convolucionais (CNNs), reunindo informações como o preço de abertura (Open), máxima (High), mínima (Low) e fechamento (Close) do ativo, volume financeiro e intervalo de tempo, em periodicidade intradiária.

Após a coleta, os dados serão sanitizados a fim de preencherem lacunas de precificação e timestamps para manter a continuidade dos dados, que será utilizada no treinamento dos modelos. Além disso, para mitigar a disparidade de magnitude entre os ativos, será aplicado a normalização Min-Max Scaler de forma independente para cada um para projetar a amplitude de variação no intervalo $[0, 1]$. A sanitização também irá incluir o escalonamento de recursos para evitar que o volume financeiro exerça uma influência desproporcional sobre os pesos da rede em detrimento das variações de preço.

3.3. Escolha do modelo e métricas de avaliação

Visando escolher um modelo para modelagem preditiva, optou-se pelo desenvolvimento de uma arquitetura híbrida composta por camadas de CNNs integradas a camadas de Long Short-Term Memory, visto que as CNNs podem lidar com a extração automática de características locais e espaciais dos dados, enquanto a LSTM processa as informações recebidas e as dependências temporais de longo prazo que forem relevantes nas decisão de uma operação financeira. Para os diferentes ativos, serão treinados modelos individuais a fim de compreender as mudanças no treinamento causadas por séries financeiras distintas.

A eficácia dos modelos será avaliada por meio de um conjunto de métricas, compreendendo métricas de erro, mais especificamente a raiz do erro quadrático médio (RMSE) e o erro absoluto médio (MAE) e métricas de direção, como a acurácia direcional. Complementarmente, métricas de negócio, como o Sharpe Ratio e Maximum Drawdown, também serão levadas em consideração para medir a viabilidade do modelo em cenários reais em operações financeiras, além de uma análise de gestão de risco utilizando a métrica de Valor em Risco simplificado (VaR).

Para fins de controle e comparativo, também será construído modelos de arquitetura singular que utilizem os modelos da arquitetura híbrida separadamente, um modelo de CNN controle, e um modelo de LSTM controle. Serão utilizados os mesmos dados de entrada, com o mesmo *pipeline* de sanitização, e serão levantadas as mesmas métricas de avaliação para realizar o comparativo.

3.4. Treinamento do modelo e testes

A fase de treinamento e de testes será conduzida seguindo estritamente o rigor cronológico, necessário para as séries temporais a fim de evitar o viés de antecipação. O conjunto de dados será particionado em três conjuntos distintos: treino, correspondente a 70% do volume total de dados, validação e teste, correspondentes a 15% cada.

Após o treinamento, os modelos serão submetidos a um processo de Backtesting, simulando o desempenho das estratégias em um ambiente controlado, permitindo a extração das métricas de negócio e de risco previamente estabelecidas.

3.5. Análise dos resultados

A seção de análise de resultados compreenderá a interpretação do desempenho dos modelos desenvolvidos. De início, será realizada uma comparação entre os ativos WIN\$ e WDO\$, avaliando qual desses ativos apresentou maior aderência à arquitetura híbrida CNN-LSTM sob a ótica das métricas de erro e acurácia, além de estimar se o modelo proposto pode ser treinado para diferentes séries financeiras.

Em sequência, os resultados dos testes serão examinados através da construção de curvas de capital (Equity Curves), permitindo a análise visual do desempenho temporal e a identificação de períodos de Drawdown. A discussão focará na correlação entre os erros do modelo e a volatilidade do mercado no período, utilizando o VaR para validar a eficácia da gestão de risco proposta. Por fim, os resultados serão confrontados com a literatura revisada, discutindo se as hipóteses de extração de padrões espaciais pelas CNNs e temporais pelas LSTMs foram confirmadas para o cenário brasileiro (B3).

4. Análises preliminares

Nessa etapa inicial do desenvolvimento, as atividades concentraram-se na modelagem e na validação estrutural das arquiteturas de Inteligência Artificial propostas. O objetivo principal foi realizar uma análise de viabilidade técnica das dimensões dos dados de entrada em relação aos fluxos internos das redes neurais, garantindo a consistência do *pipeline* antes da integração com os dados reais dos mercados futuros.

Foram desenvolvidos e compilados com sucesso três modelos computacionais distintos utilizando a biblioteca TensorFlow e Keras: a arquitetura híbrida principal experimental, mesclando CNN e LSTM, e dois modelos de controle de base, de arquitetura

singular, uma utilizando apenas CNN e outra utilizando apenas LSTM. Para fins de teste preliminar, estabeleceu-se uma matriz de entrada teórica baseada em uma janela temporal de 60 minutos contendo as 5 variáveis fundamentais do ativo: abertura, alta, baixa, fechamento e volume financeiro., resultando em um tensor bidimensional de formato (60, 5).

Table 1. Sumário Estrutural da Arquitetura Híbrida CNN-LSTM

Camada (Tipo)	Formato da Saída (Output Shape)	Parâmetros (#)
conv1d (Conv1D)	(None, 58, 64)	1.024
max_pooling1d (MaxPooling1D)	(None, 29, 64)	0
dropout (Dropout)	(None, 29, 64)	0
conv1d_1 (Conv1D)	(None, 27, 32)	6.176
max_pooling1d_1 (MaxPooling1D)	(None, 13, 32)	0
dropout_1 (Dropout)	(None, 13, 32)	0
lstm (LSTM)	(None, 50)	16.600
dropout_2 (Dropout)	(None, 50)	0
dense (Dense)	(None, 25)	1.275
dense_1 (Dense)	(None, 1)	26
Total de Parâmetros Treináveis:		25.101
Parâmetros Não Treináveis:		0

Table 2. Sumário Estrutural da Arquitetura CNN pura

Camada (Tipo)	Formato da Saída (Output Shape)	Parâmetros (#)
conv1d_2 (Conv1D)	(None, 58, 64)	1.024
max_pooling1d_2 (MaxPooling1D)	(None, 29, 64)	0
dropout_3 (Dropout)	(None, 29, 64)	0
conv1d_3 (Conv1D)	(None, 27, 32)	6.176
max_pooling1d_3 (MaxPooling1D)	(None, 13, 32)	0
dropout_4 (Dropout)	(None, 13, 32)	0
flatten (Flatten)	(None, 416)	0
dense_2 (Dense)	(None, 25)	10.425
dense_3 (Dense)	(None, 1)	26
Total de Parâmetros Treináveis:		17.651
Parâmetros Não Treináveis:		0

Table 3. Sumário Estrutural da Arquitetura LSTM pura

Camada (Tipo)	Formato da Saída (Output Shape)	Parâmetros (#)
lstm_1 (LSTM)	(None, 60, 64)	17.920
dropout_5 (Dropout)	(None, 60, 64)	0
lstm_2 (LSTM)	(None, 32)	12.416
dropout_6 (Dropout)	(None, 32)	0
dense_4 (Dense)	(None, 25)	825
dense_5 (Dense)	(None, 1)	26
Total de Parâmetros Treináveis:		31.187
Parâmetros Não Treináveis:		0

Os sumários de execução confirmaram que a matemática de compressão dimensional das camadas está operando conforme o planejado. No modelo híbrido, a primeira camada (Conv1D) reduziu a dimensão temporal para 58 intervalos enquanto expandiu a capacidade de extração para 64 mapas de características. O processo de *Max Pooling* reduziu o ruído dimensional pela metade, permitindo que a camada de LSTM processe uma sequência altamente filtrada e concentrada de apenas 13 momentos com 32 recursos.

Sob a perspectiva da eficiência computacional, a análise preliminar dos parâmetros revelou que o modelo híbrido totaliza 25.101 parâmetros treináveis. Esse valor indica que a rede possui uma arquitetura leve e de baixo custo computacional, confirmando a viabilidade de sua execução e treinamento local em um ambiente de computação pessoal, sem a dependência obrigatória de clusters de alta performance. Além disso, o número contido de parâmetros mitiga o risco de *overfitting*, assegurando que o modelo possua capacidade de generalização ao ser exposto aos dados reais de mercado.

5. Considerações finais

As atividades desenvolvidas até o presente momento consolidaram a base teórica e a estrutura computacional necessárias para a execução do estudo proposto. A revisão sistemática de literatura permitiu mapear o estado da arte em modelos preditivos para o mercado financeiro, fundamentando a escolha pela arquitetura híbrida CNN-LSTM em detrimento de abordagens de modelos singulares, as quais serão utilizadas como modelos de controle.

A modelagem e compilação bem-sucedidas das redes neurais no ambiente de desenvolvimento validaram a integridade do fluxo de dados e confirmaram a viabilidade técnica do projeto. Com uma estrutura contida de 25.101 parâmetros treináveis para o modelo híbrido, assegurou-se a capacidade de processamento local em hardware convencional, eliminando gargalos de infraestrutura computacional e minimizando riscos de *overfitting*.

Com a codificação dos modelos e as funções de janelamento temporal (sliding windows) previamente estruturadas, o trabalho encontra-se em estágio de prontidão para a sua fase prática. Os próximos passos compreenderão a extração das séries temporais intradiárias do Mini Índice e Mini Dólar diretamente da plataforma MetaTrader 5, seguida pelos processos de normalização e alinhamento de dados. Posteriormente, será iniciada a

fase de treinamento, sintonização de hiperparâmetros e execução do Backtesting, cujos resultados econômicos e estatísticos preencherão as seções finais desta pesquisa, permitindo validar a real eficácia da arquitetura proposta na mitigação de riscos e identificação de tendências no mercado futuro brasileiro.

References

- Al-Alawi, A. I. and Alaali, Y. A. (2023). Stock market prediction using machine learning techniques: Literature review analysis. *2023 International Conference On Cyber Management And Engineering (CyMaEn)*, pages 195–201.
- Aliyev, F., Eylasov, N., and Gasim, N. (2022). Applying deep learning in forecasting stock index: Evidence from rts index. *2022 IEEE 16th International Conference on Application of Information and Communication Technologies (AICT)*, pages 1–5.
- Baswaraj, D., Natchadalingam, R., Rekha, R. S., Sahni, N., Divya, V., and Reddy, P. C. S. (2023). An accurate stock prediction using ensemble deep learning model. *2023 International Conference on Research Methodologies in Knowledge Management, Artificial Intelligence and Telecommunication Engineering (RMKMATE)*, pages 1–6.
- Jaswanth, B. and Kaushik, J. (2022). Stacked lstm a deep learning model to predict stock market. *2022 4th International Conference on Advances in Computing, Communication Control and Networking (ICAC3N)*, pages 1827–1831.
- Jin, S. (2025a). Research on g-var prediction of stock market risk based on deep learning. In *Proceedings of the 2025 2nd International Conference on Digital Economy, Blockchain and Artificial Intelligence*, pages 138–143.
- Jin, Y. (2025b). Graphcnnpred: A stock market indices prediction using a graph based deep learning system. In *Proceedings of the 2024 2nd International Conference on Artificial Intelligence, Systems and Network Security (AISNS '24)*, pages 176–181, New York, NY, USA. Association for Computing Machinery.
- Khan, M., Dey, R., Kassim, S., Mahajan, R. A., Ghosh, A., and William, P. (2025). Machine learning-driven trading strategies: An empirical analysis of bse blue-chip stocks using advanced algorithmic approaches. *2025 International Conference on Quantum Photonics, Artificial Intelligence, and Networking (QPAIN)*, pages 1–7.
- Khan, R. H., Miah, J., Rahman, M. M., Hasan, M. M., and Mamun, M. (2023). A study of forecasting stocks price by using deep reinforcement learning. *2023 IEEE World AI IoT Congress (AIIoT)*, pages 446–452.
- Khurelbaatar, S. and Togtokh, G. (2025). Stock market prediction using deep learning models: The case of mongolian stocks. In *Proceedings of the 2025 2nd International Conference on Digital Economy and Computer Science*, pages 1–6.
- Li, Z. (2024). Tlapc: A hybrid deep learning model for stock market prediction. In *Proceedings of the 2024 3rd International Conference on Cyber Security, Artificial Intelligence and Digital Economy*, pages 482–486.
- Luthfianti, B. A., Saepudin, D., and Ihsan, A. F. (2022). Portfolio allocation of stocks in index lq45 using deep reinforcement learning. *2022 10th International Conference on Information and Communication Technology (ICoICT)*, pages 488–492.

- Meena, J. K. and Banyal, R. K. (2024). Overview of advanced deep learning based models for stock market price predictions. In *Proceedings of the 5th International Conference on Information Management & Machine Intelligence*, pages 1–8.
- Mohammed, S. (2022). The validity of using technical indicators when forecasting stock prices using deep learning models. *2022 14th International Conference on Computational Intelligence and Communication Networks (CICN)*, pages 605–609.
- Patil, P. S., Kukreja, V., Upadhyay, D., Manwal, M., and Sharma, R. (2024). A long short-term memory technique for nifty50 stocks price prediction. *2024 Asia Pacific Conference on Innovation in Technology (APCIT)*, pages 1–6.
- Saini, A., Singh, N., Singh, R. K., and Sachan, M. K. (2024). Financial time series prediction on apple stocks using machine and deep learning models. *2024 International Conference on Electrical, Computer and Energy Technologies (ICECET)*, pages 1–6.
- Yang, W. (2025). Research on stock market sentiment analysis and prediction. In *Proceedings of the ACM Conference*.
- Zhu, Y. (2024). A comparative analysis of deep learning models in stock market prediction. In *Proceedings of the ACM Conference*.